지능형 멀티미디어 시스템

# 데이터 증강에 따른 COVID-19 이미지 분류모델 성능 비교

TEAM 꿀벌

# 프로젝트 소개 : 무엇이 목표인가?

## ▶ COVID 19 IMAGE SEGMENTATION 데이터 증강 성능 비교

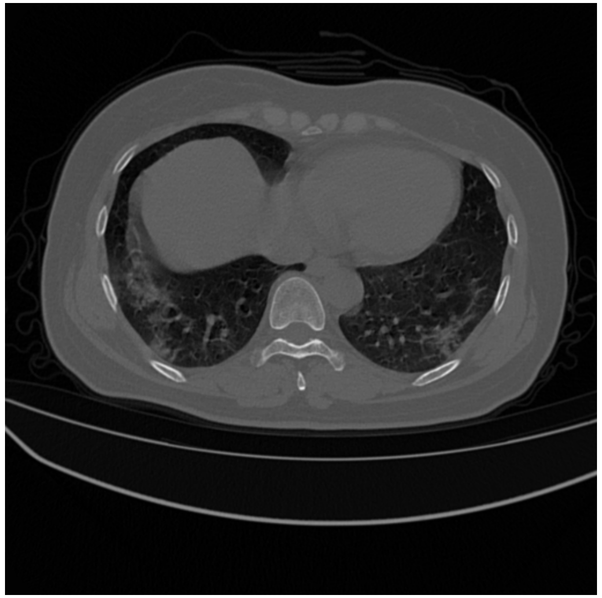

* 이미지내에 특정 부분을 추출해내는 과제

### 의료데이터에서의 데이터 증강 성능

- GAN을 통해서 데이터 증강을 하고 다른 증강과 섞어볼까?
- JPEG의 문제점인 디지털 풍화를 모델 학습에 적용시킨다면?
- GAN을 통한 GAN의 재 학습 이미지는 어떤 모습이고 학습에 적용 시킬 수 있을까?
- UNET에서 우수한 성능을 보인 데이터 증강을 VIT에 학습시킨다면?
- UNET GAN 이외의 GAN의 성능은 어떨까?
- 딥러닝의 구성요소 3가지 모델, 데이터, loss함수
- 어떤 loss함수가최적의 결과를 보일까?

# 프로젝트 소개 : 어떤 데이터를 사용했나?

▶ COVID-19 CT scan lesion segmentation dataset

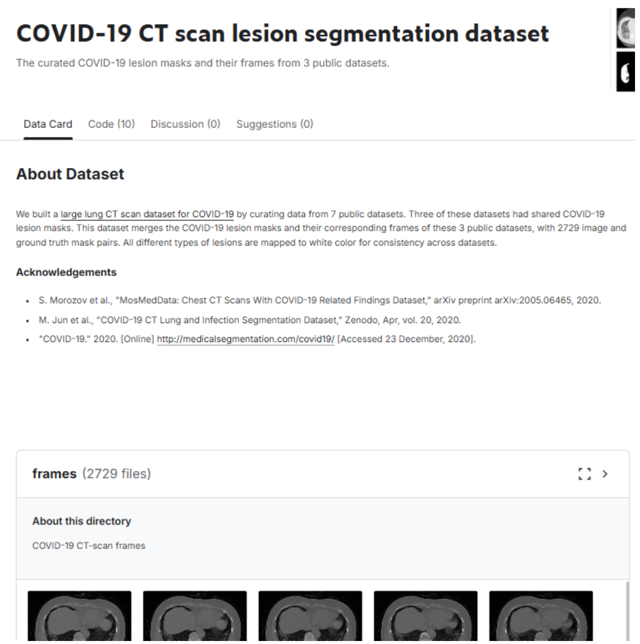

## COVID-19 CT scan lesion segmentation dataset

The curated COVID-19 lesion masks and their frames from 3 public datasets.

Data Card Code (10) Discussion (0) Suggestions (0)

### About Dataset

We built a large lung CT scan dataset for COVID-19 by curating data from 7 public datasets. Three of these datasets had shared COVID-19 lesion masks. This dataset merges the COVID-19 lesion masks and their corresponding frames of these 3 public datasets, with 2729 image and ground truth mask pairs. All different types of lesions are mapped to white color for consistency across datasets.

**Acknowledgements**

- S. Morozov et al., "MosMedData: Chest CT Scans With COVID-19 Related Findings Dataset," arXiv preprint arXiv:2005.06465, 2020.
- M. Jun et al., "COVID-19 CT Lung and Infection Segmentation Dataset," Zenodo, Apr, vol. 20, 2020.
- "COVID-19." 2020. [Online] http://medicalsegmentation.com/covid19/ [Accessed 23 December, 2020].

**frames** (2729 files)

About this directory

COVID-19 CT-scan frames

＊ 2727장의 마스크와 이미지

512 × 512 px

병변vs 배경

이진 segmentation

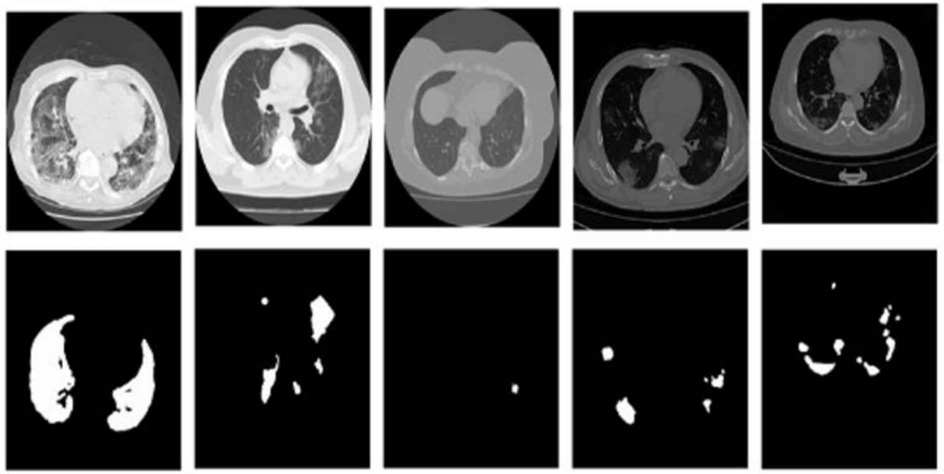

＊ Kaggle을 통해서 배포되어 있는 데이터셋

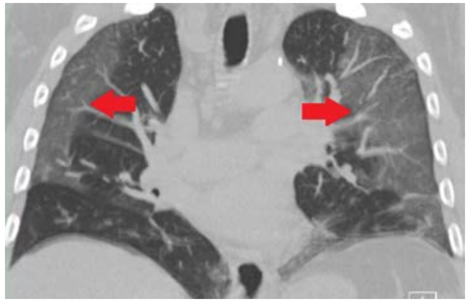

## Ground-Glass

주위 조직·혈관 구조가 보일 정도로 반투명하게 흐린 영역을 말합니다.

## Consolidation

흉부 CT에서 폐포 내에 액체성분이 가득 차 폐 조직이 실질적으로 치밀해져 흰색으로 보이는 소견을 말합니다.

# 데이터 증강

데이터 증강

- **GAN - UNET**
  Image-to-Image Translation with Conditional Adversarial Networks
  Phillip Isola, Jun-Yan Zhu, Tinghui Zhou, Alexei A. Efros CVPR 2017
- **Flip/Rotate vs Elastic vs MixUp vs JPEG 등**

추가로 시도해 보고자 하는 것 - JPEG의 디지털 풍화

*원본

*30 압축 4번

*30 압축 18번

*30 압축 30번

# 디지털 풍화

## 데이터 증강으로 JPEG을 사용하면서 든 생각 → 디지털 풍화를 시켜 모델에 학습시킨다면 어떤 결과가 나올 것인가?

＊30 압축

＊30 – 20 -10 - 5압축

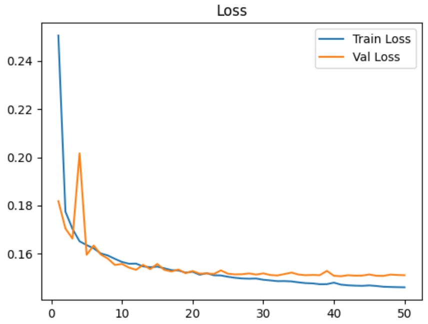


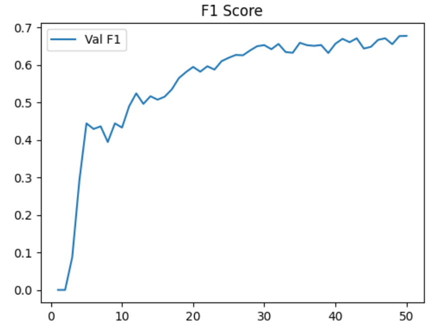


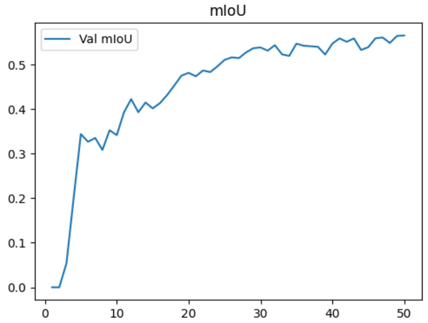


Test Loss : 0.1512
Test F1 : 0.6675
Test mIoU : 0.5603

### 디지털 풍화란?

디지털 데이터나 이미지가 압축, 변환, 저장, 전송, 복사 과정에서 반복적으로 처리되며, 원본 품질이 점진적으로 손실되는 현상을 말합니다.

# 데이터 증강 비교

$$G_\sigma(x,y) = \frac{1}{2\pi\sigma^2} e^{\left(\frac{x^2+y^2}{2\sigma^2}\right)} \quad \begin{cases} \mu_x = \mu_y = 0 \\ \sigma_x = \sigma_y = \sigma \end{cases}$$

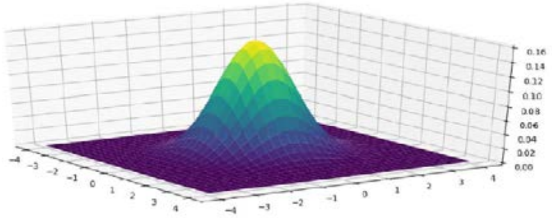


## Elastic 대신에 JPEG을 사용할 수 있을까?

이미지를 랜덤하게 비틀어(탄성 변형) 실제 조직이나 객체가 자연스럽게 변형된 것처럼 만들어 줌

국소적인 왜곡(local deformation)을 통해 모델이 모양 변화에 강건해지도록 함

가우시안 필터를 사용하여 스무딩, 매우작은 영역에서 변위가 진행됨

* elastic

* mixup

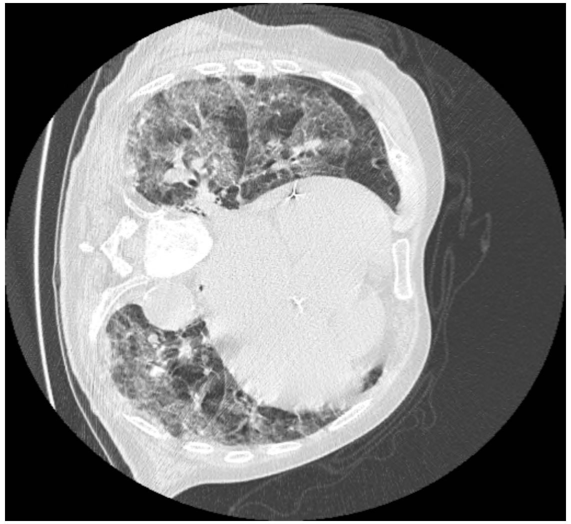

* flip/rotate

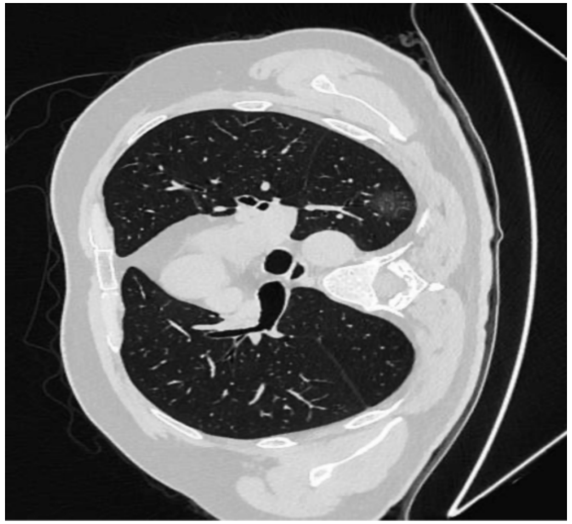

* flip/rotate

# UNET - GAN

Image-to-Image Translation with Conditional Adversarial Networks Phillip Isola, Jun-Yan Zhu, Tinghui Zhou, Alexei A. Efros CVPR 2017c

## Generator: U-Net

점점 receptive field(수렴 영역)를 넓혀가며, “대략 이 영역에 이런 객체가 있다”는 높은 수준의 맥락 정보를 추출

## Discriminator: PatchGAN

이미지 전체가 아니라, N×N 크기 패치단위로 진짜/가짜 판별

## L1 Loss

$$\min_G \max_D \left[\mathcal{L}_{cGAN}(G, D) + \lambda \mathcal{L}_{L1}(G)\right]$$

IMG_SIZE = 256
BATCH_SIZE = 8
EPOCHS = 50
LR = 2e-4
L1_LAMBDA = 100
NUM_SAMPLES = 2500

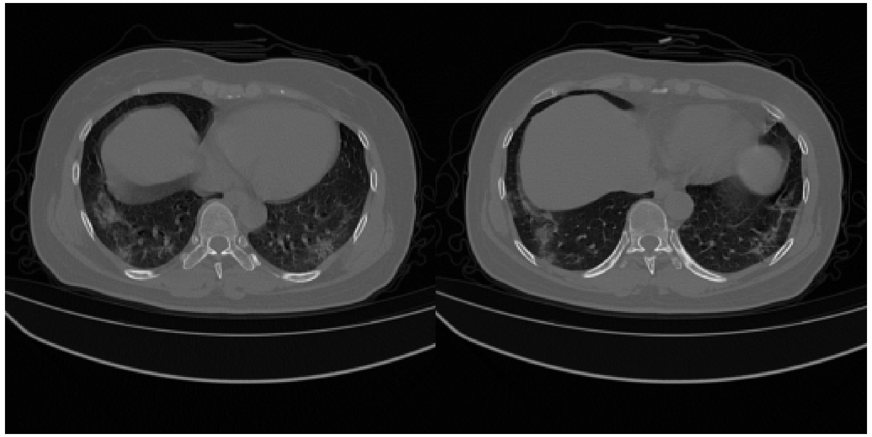

*frame

*Mask

# DAGAN

Data Augmentation Generative Adversarial Networks Antreas Antoniou, Amos Storkey, Harrison Edwards arXiv preprint arXiv Nov 2017

"같은 클래스 내 진짜 같은 가짜" 를 생성함으로써,
데이터 소량 환경에서도 모델의 일반화 능력을 크게 향상시키는 강력한 증강 기법

## Generator

원본 이미지 x + 노이즈 벡터 z

## Discriminator

조건부 PatchGAN + 스펙트럴 노멀라이제이션
→ 국소 질감(realism) 을 학습

IMG_SIZE = 256
BATCH_SIZE = 8
EPOCHS = 50
LR = 2e-4
L1_LAMBDA = 100
NUM_SAMPLES = 2500

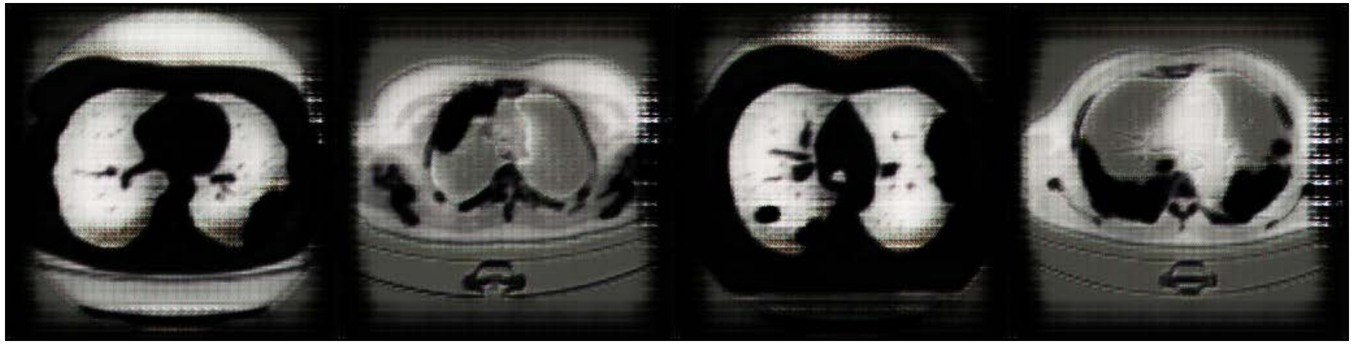

*frame

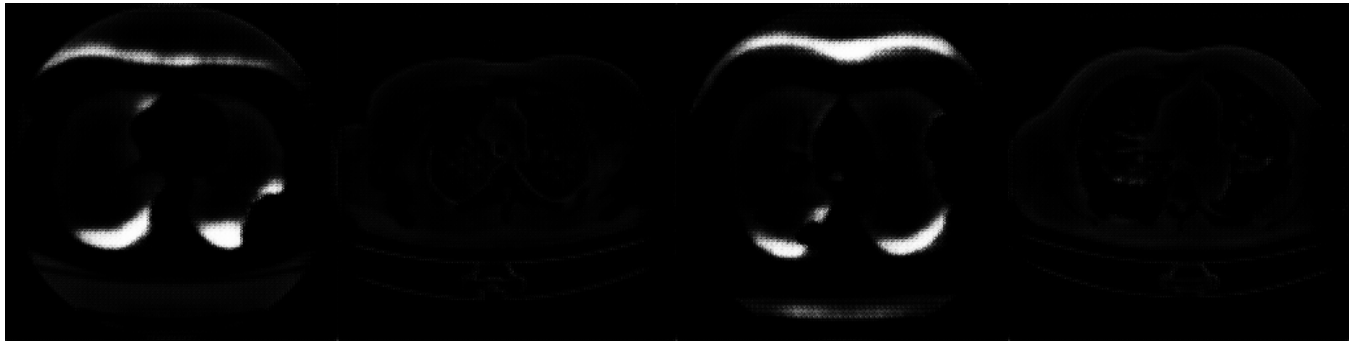

*Mask

# GAN 을 활용한 GAN 학습

Image-to-Image Translation with Conditional Adversarial Networks Phillip Isola, Jun-Yan Zhu, Tinghui Zhou, Alexei A. Efros CVPR 2017c

원본 이미지

↓

UNET GAN학습

↓

이미지 생성

↓

GAN 재 학습

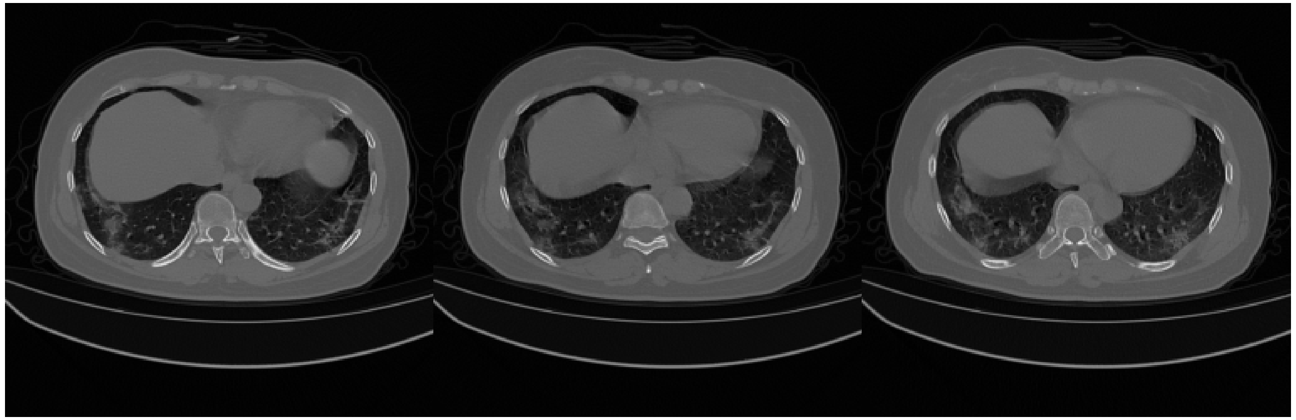

*frame

*Mask

# 모델의 성능 비교 - LOSS

$$L_{BCE} = -\frac{1}{n}\sum_{i=1}^{n}(Y_i \cdot \log \hat{Y}_i + (1 - Y_i) \cdot \log (1 - \hat{Y}_i))$$

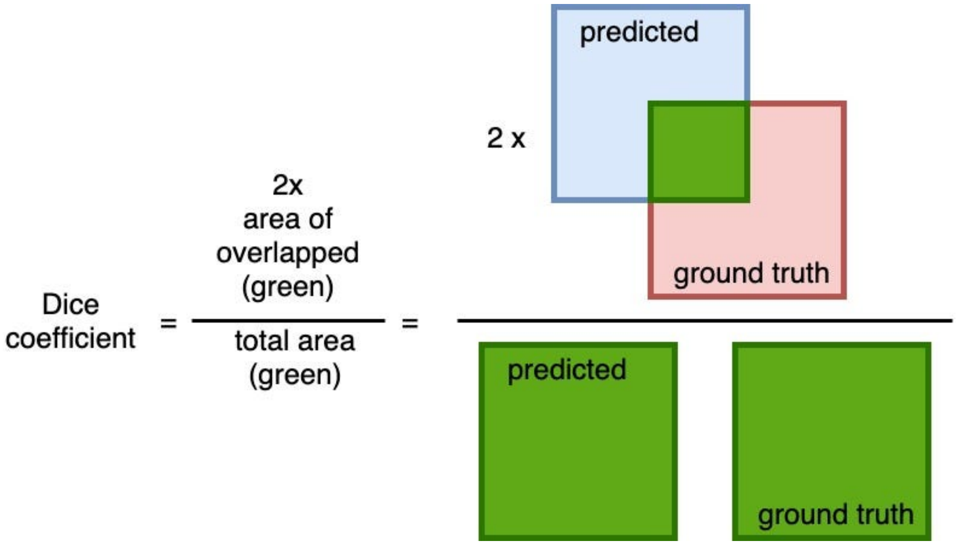


## BCE(Binary Cross Entropy Loss)란?

Segmentaion에서 마스크의 안과 밖을 예측하는 문제에서 사용된다.

H,WH,WH,W는 출력 마스크의 높이와 너비

각 픽셀 (i,j)(i,j)(i,j) 에 대해 이진 교차 엔트로피를 계산하고, 전체 픽셀 평균을 구함

## Dice Loss란?

두 이진 마스크 사이의 유사도를 측정하는 함수 MIOU는 교집합을 한번만 포함하지만 DICE는 교집합을 두 번 포함

Dice는 F1-score 관점에서 “정밀도(Precision)·재현율(Recall)”을 직접 최적화하는 효과가 있음

작은 마스크에 효과적

비교 분석

# 데이터 증강에 따른 모델 성능비교

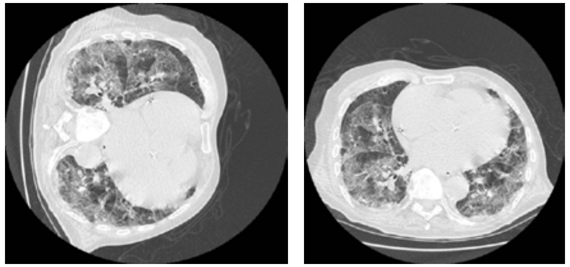

Flip/rotate + elastic

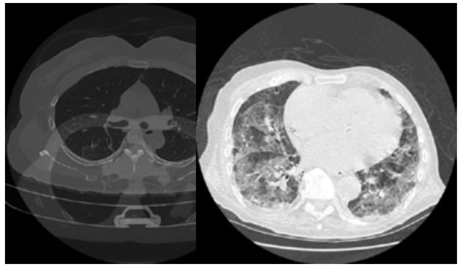

Mixup + jpeg

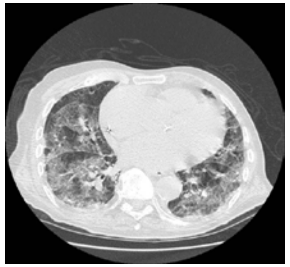

Origin(대조군)

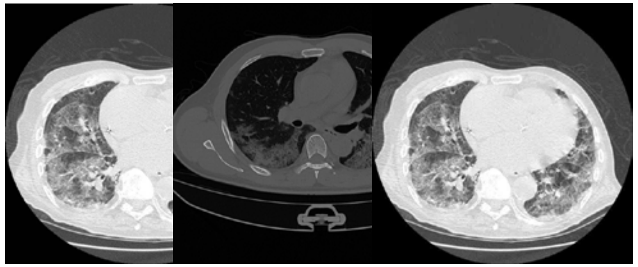

Origin + gan + jpeg

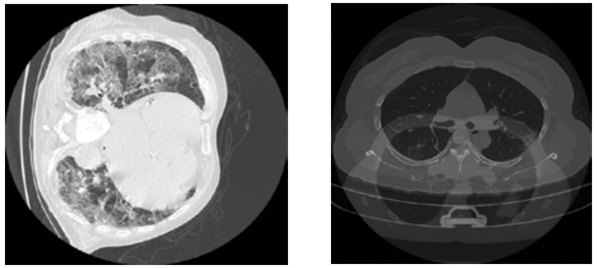

Flip/rotate + mixup

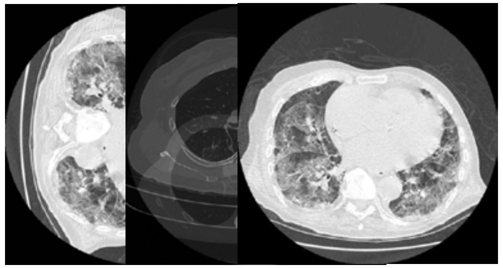

Flip/rotate + Mixup + jpeg

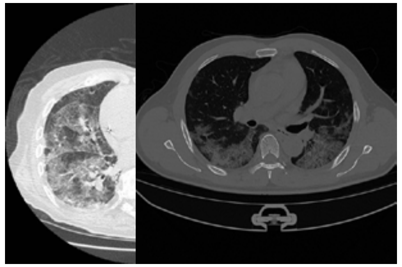

Origin + gan

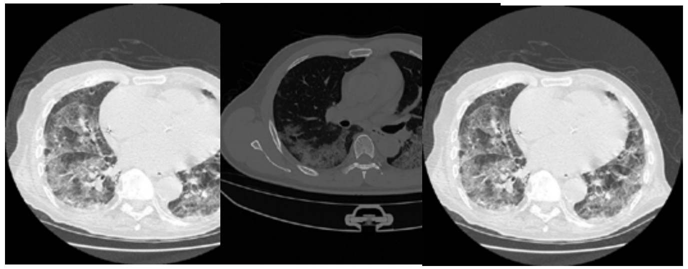

Origin + gan + elastic

**Segmentation 에서의 증강성능 검증할 8개의 실험계획**

## 데이터 증강 비교

# 모델 학습

U-Net: Convolutional Networks for Biomedical Image Segmentation  Olaf Ronneberger, Philipp Fischer, Thomas Brox MICCAI 2015

*** Train/val = 0.75/0.25**

**COVID-19 CT scan lesion segmentation dataset**

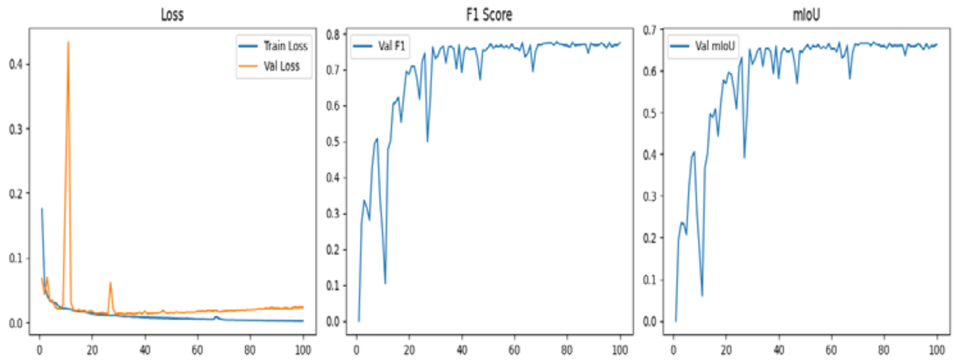


***origin**

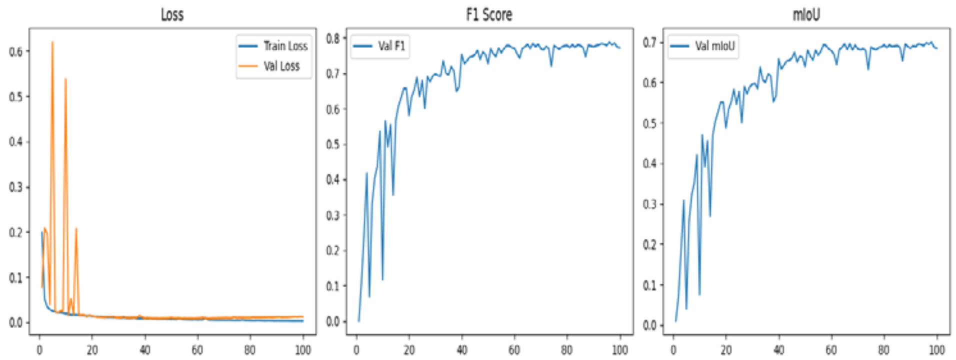


***origin  + gan + elastic**

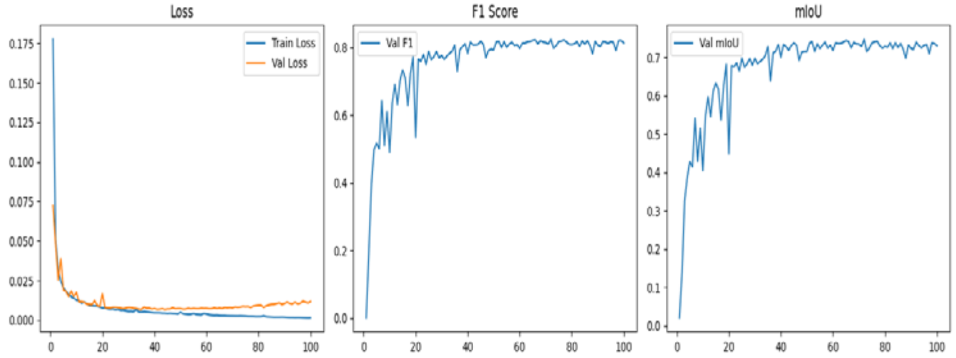


***origin + gan**

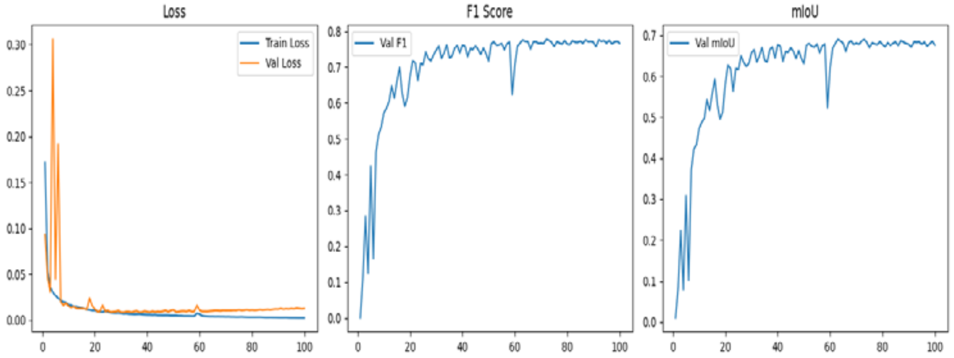


***origin + gan + jpeg**

# 모델 학습

U-Net: Convolutional Networks for Biomedical Image Segmentation  Olaf Ronneberger, Philipp Fischer, Thomas Brox MICCAI 2015

*** Train/val = 0.75/0.25**

**COVID-19 CT scan lesion segmentation dataset**

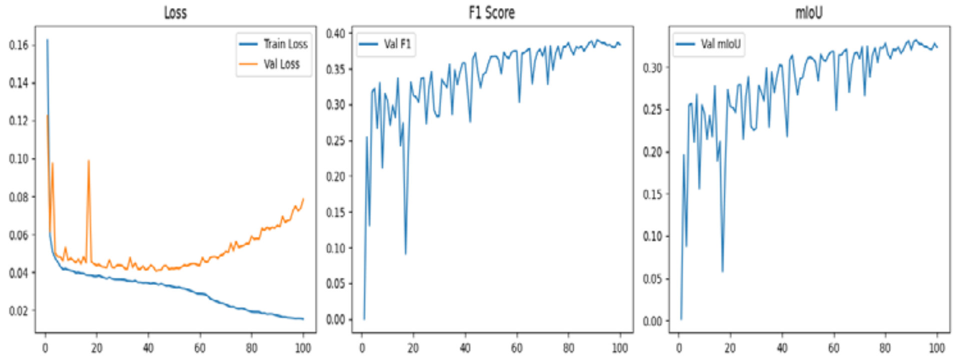


***Flip/rotate + mixup**

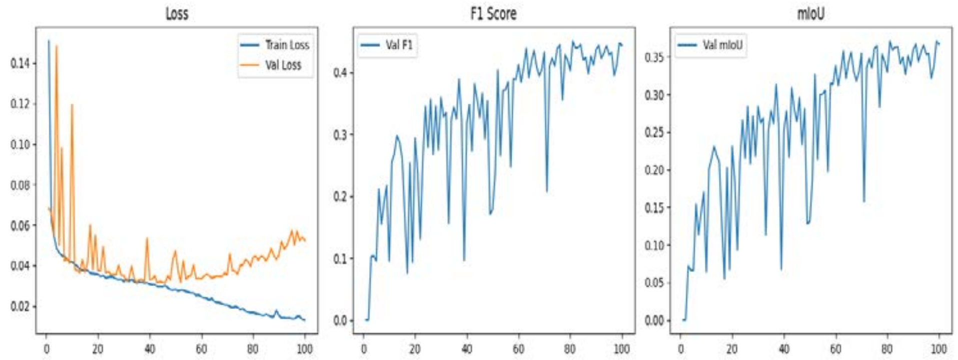


***Flip/rotate + mixup + jpeg**

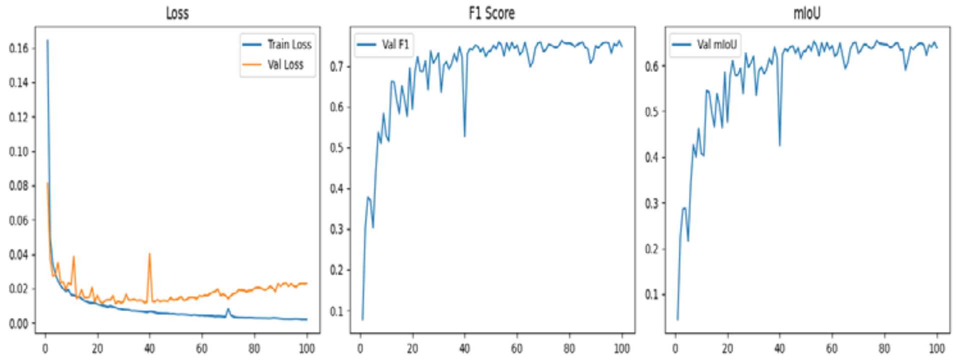


***Flip/rotate + elastic**

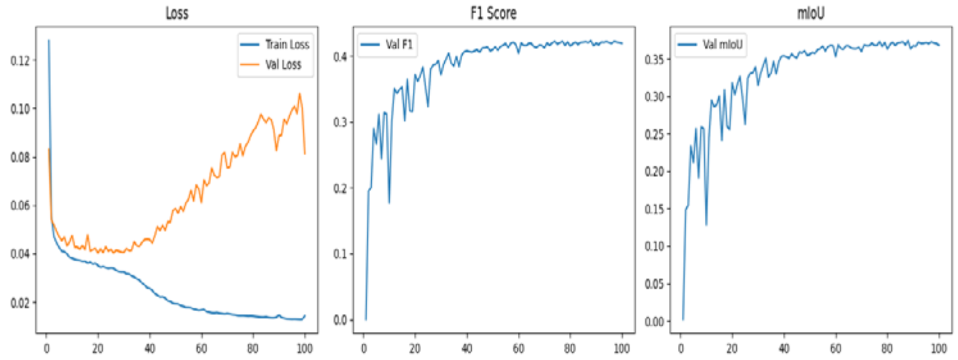


***mixup + jpeg**

## 데이터 증강 비교

# 모델 학습

U-Net: Convolutional Networks for Biomedical Image Segmentation  Olaf Ronneberger, Philipp Fischer, Thomas Brox MICCAI 2015

*** 50 epoch Test set 결과**

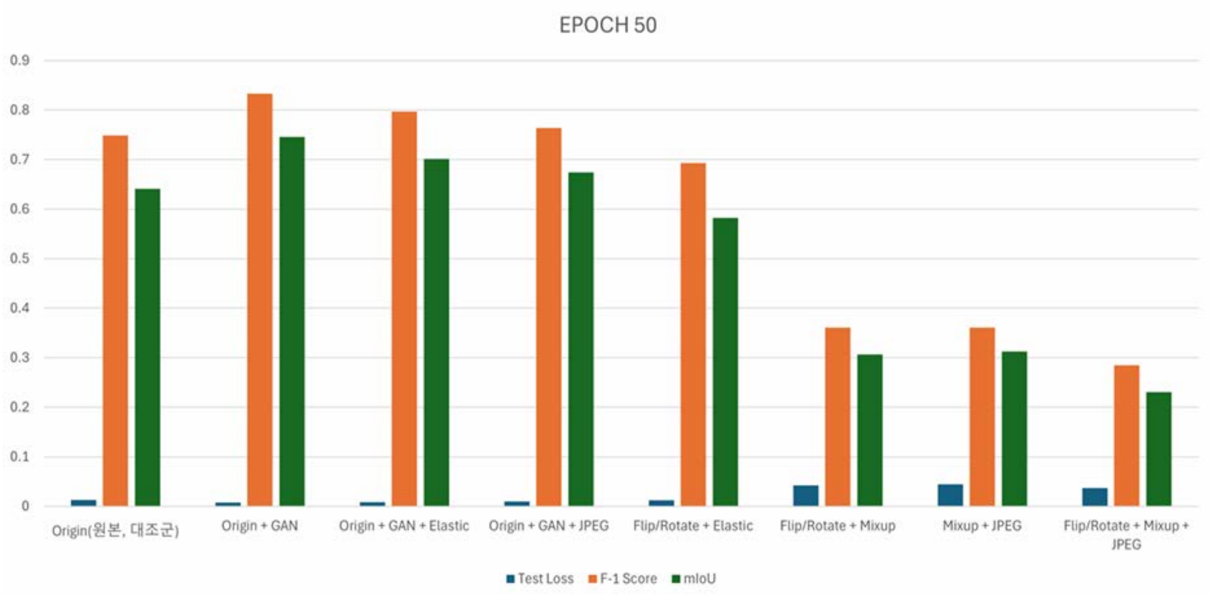


| 증강된 데이터 종류 | Test Loss | F-1 Score | mIoU |
|---|---|---|---|
| Origin(원본, 대조군) | 0.0127 | 0.7489 | 0.6410 |
| Origin + GAN | 0.0073 | 0.8333 | 0.7460 |
| Origin + GAN + Elastic | 0.0084 | 0.7968 | 0.7014 |
| Origin + GAN + JPEG | 0.0099 | 0.7641 | 0.6741 |
| Flip/Rotate + Elastic | 0.0117 | 0.6928 | 0.5824 |
| Flip/Rotate + Mixup | 0.0423 | 0.3606 | 0.3064 |
| Mixup + JPEG | 0.0442 | 0.3608 | 0.3125 |
| Flip/Rotate + Mixup + JPEG | 0.0367 | 0.2847 | 0.2304 |

**가장 안 좋은 성능을 보이는 데이터 증강의 조합**

- Flip/Rotate + Mixup
- Mixup + JPEG
- Flip/Rotate + Mixup + JPEG

IMAGE_SIZE = 256 NUM_SAMPLES = 2700 BATCH_SIZE = 8
EPOCHS = 50  LEARNING_RATE = 1e-3 BCE loss

데이터 증강 비교

## 모델 학습

U-Net: Convolutional Networks for Biomedical Image Segmentation  Olaf Ronneberger, Philipp Fischer, Thomas Brox MICCAI 2015

*** 100 epoch Test set 결과**

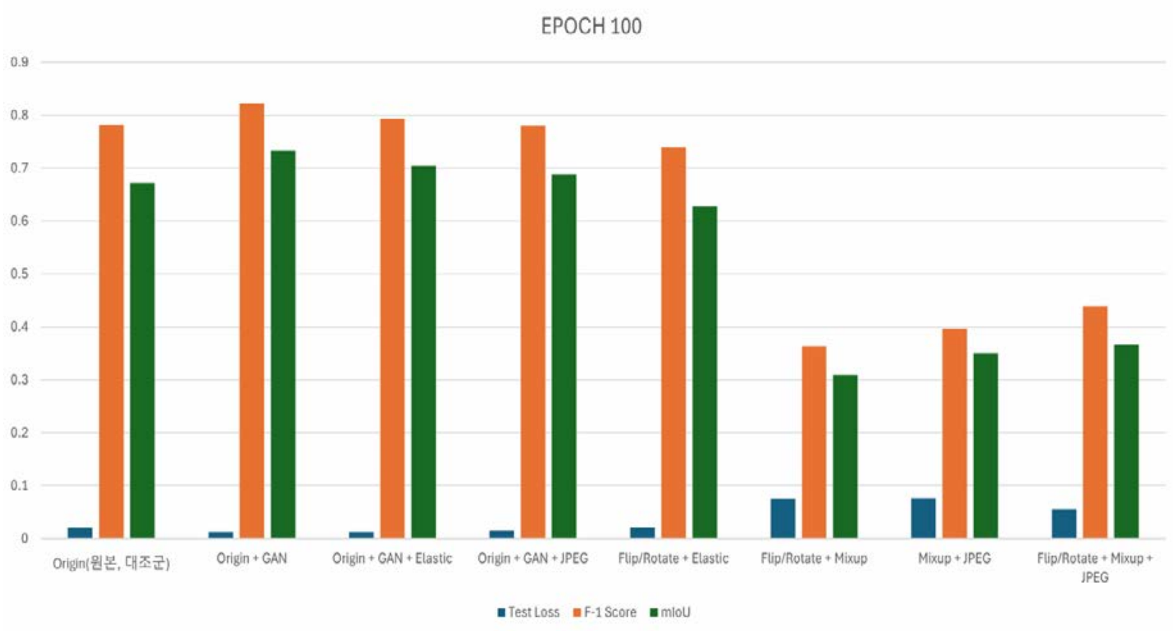


| 증강된 데이터 종류 | Test Loss | F-1 Score | mIoU |
|---|---|---|---|
| Origin (원본, 대조군) | 0.0202 | 0.7825 | 0.6722 |
| Origin + GAN | 0.0125 | 0.8221 | 0.7327 |
| Origin + GAN + Elastic | 0.0124 | 0.7940 | 0.7038 |
| Origin + GAN + JPEG | 0.0141 | 0.7803 | 0.6888 |
| Flip/Rotate + Elastic | 0.0207 | 0.7388 | 0.6275 |
| Flip/Rotate + Mixup | 0.0754 | 0.3638 | 0.3096 |
| Mixup + JPEG | 0.0760 | 0.3966 | 0.3503 |
| Flip/Rotate + Mixup + JPEG | 0.0546 | 0.4387 | 0.3659 |

**가장 안정적이고 좋은 결과를 보이는 데이터 증강의 조합**

**origin  + gan**

**origin  + gan + elastic**

IMAGE_SIZE = 256 NUM_SAMPLES = 2700 BATCH_SIZE = 8
EPOCHS = 100  LEARNING_RATE = 1e-3 BCE loss

# 모델 학습

U-Net: Convolutional Networks for Biomedical Image Segmentation Olaf Ronneberger, Philipp Fischer, Thomas Brox MICCAI 2015

* 50 epoch Test set 결과

## DICE LOSS사용시 변화

| 증강된 데이터 종류 | Test Loss | F-1 Score | mIoU |
|---|---|---|---|
| Origin (원본, 대조군) | 0.0127 | 0.7489 | 0.6410 |
| Origin + GAN + Elastic | 0.0073 | 0.8333 | 0.7460 |
| Origin + GAN | 0.0124 | 0.7940 | 0.7038 |

*BCE LOSS

| 증강된 데이터 종류 | Test Loss | F-1 Score | mIoU |
|---|---|---|---|
| Origin (원본, 대조군) | 0.2517 | 0.7494 | 0.6315 |
| Origin + GAN + Elastic | 0.2347 | 0.7667 | 0.6607 |
| Origin + GAN | 0.2902 | 0.7044 | 0.6010 |

*DICE LOSS

IMAGE_SIZE = 256 NUM_SAMPLES = 2700 BATCH_SIZE = 8
EPOCHS = 50 LEARNING_RATE = 1e-3 DICE loss

# 데이터 증강 비교

## SegFormer에 적용

SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers
Enze Xie, Wenhai Wang, Zhiding Yu, Anima Anandkumar, José M. Alvarez, Ping Luo. *CVPR 2021*

*** 50 epoch Test set 결과**

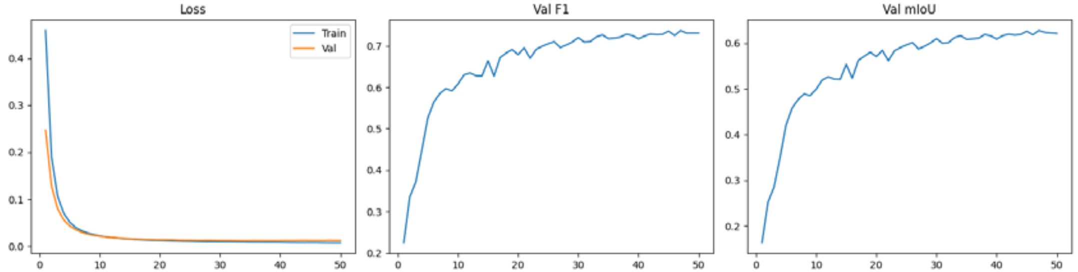


***origin**

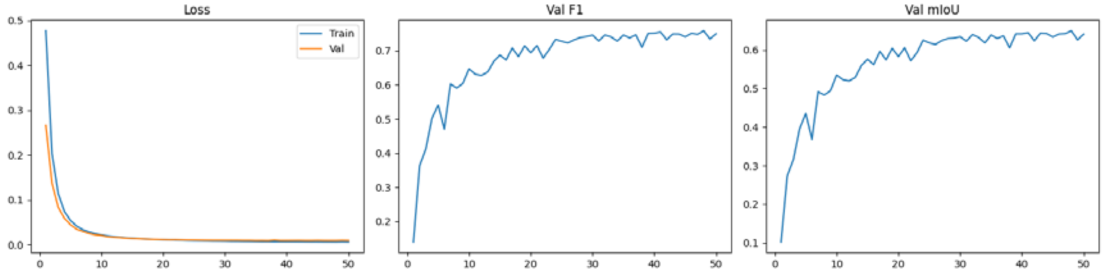


***origin + gan + elastic**

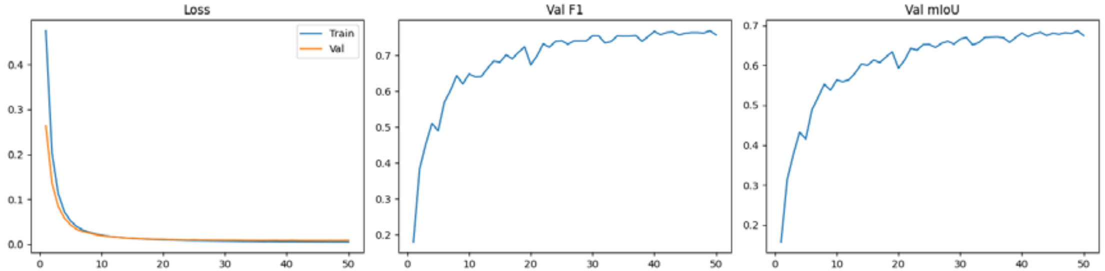


***origin + gan**

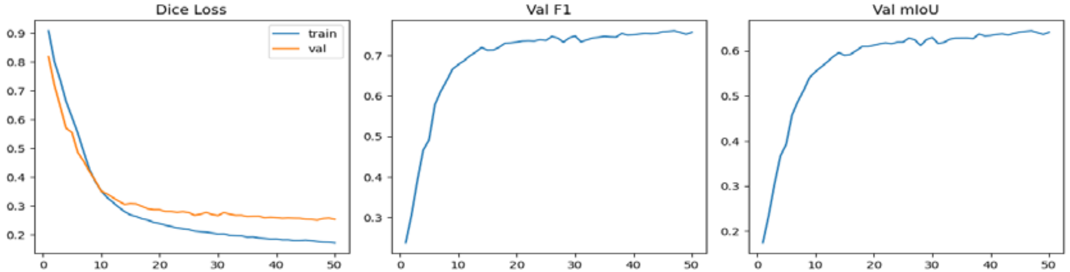


***origin**

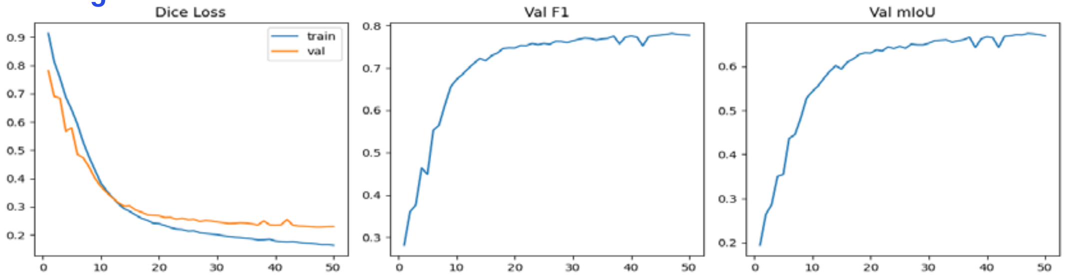


***origin + gan + elastic**

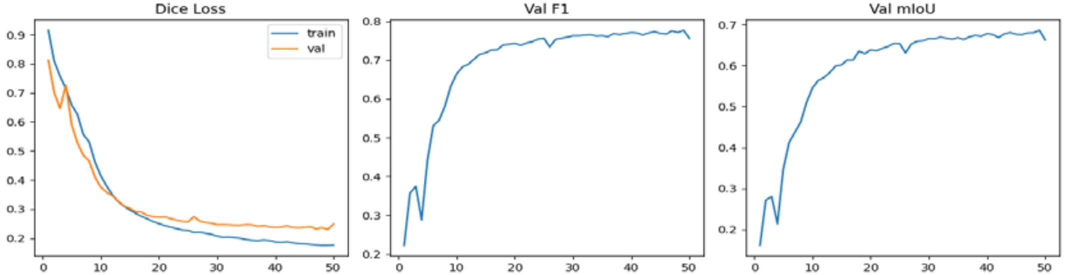


***origin + gan**

IMAGE_SIZE = 256 NUM_SAMPLES = 2700 BATCH_SIZE = 8
EPOCHS = 50 LEARNING_RATE= 6e-5

데이터 증강 비교

# SegFormer에 적용 * 50 epoch Test set 결과

SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers Enze Xie, Wenhai Wang, Zhiding Yu, Anima Anandkumar, José M. Alvarez, Ping Luo. *CVPR 2021*

| 증강된 데이터 종류 | Test Loss | F-1 Score | mIoU |
|---|---|---|---|
| Origin (원본, 대조군) | 0.0125 | 0.7448 | 0.6361 |
| Origin + GAN + Elastic | 0.0085 | 0.7534 | 0.6511 |
| Origin + GAN | 0.0081 | 0.7556 | 0.6705 |

*BCE LOSS

| 증강된 데이터 종류 | Test Loss | F-1 Score | mIoU |
|---|---|---|---|
| Origin (원본, 대조군) | 0.2502 | 0.7599 | 0.6481 |
| Origin + GAN + Elastic | 0.2331 | 0.7761 | 0.6705 |
| Origin + GAN | 0.2307 | 0.7756 | 0.6824 |

*DICE LOSS

**VIT에서는 DICE LOSS가 우수한 성능을 보인다**

IMAGE_SIZE = 256 NUM_SAMPLES = 2700 BATCH_SIZE = 8
EPOCHS = 50 LEARNING_RATE= 6e-5

모델성능 비교

# UNET VS SegFormer * 50 epoch Test set 결과

| 증강된 데이터 종류 | Test Loss | F-1 Score | mIoU |
|---|---|---|---|
| Origin (원본, 대조군) | 0.0127 | 0.7489 | 0.6410 |
| Origin + GAN + Elastic | 0.0073 | 0.8333 | 0.7460 |
| Origin + GAN | 0.0124 | 0.7940 | 0.7038 |

*BCE LOSS ,UNET

| 증강된 데이터 종류 | Test Loss | F-1 Score | mIoU |
|---|---|---|---|
| Origin (원본, 대조군) | 0.0125 | 0.7448 | 0.6361 |
| Origin + GAN + Elastic | 0.0085 | 0.7534 | 0.6511 |
| Origin + GAN | 0.0081 | 0.7556 | 0.6705 |

*BCE LOSS ,VIT

| 증강된 데이터 종류 | Test Loss | F-1 Score | mIoU |
|---|---|---|---|
| Origin (원본, 대조군) | 0.2517 | 0.7494 | 0.6315 |
| Origin + GAN + Elastic | 0.2347 | 0.7667 | 0.6607 |
| Origin + GAN | 0.2902 | 0.7044 | 0.6010 |

*DICE LOSS ,UNET

| 증강된 데이터 종류 | Test Loss | F-1 Score | mIoU |
|---|---|---|---|
| Origin (원본, 대조군) | 0.2502 | 0.7599 | 0.6481 |
| Origin + GAN + Elastic | 0.2331 | 0.7761 | 0.6705 |
| Origin + GAN | 0.2307 | 0.7756 | 0.6824 |

*DICE LOSS , VIT

# 연구들과 비교 MedSegBench: 14-dataset benchmark incl. COVID-19 CT lesion – Nat. Sci. Data 2024

| 증강된 데이터 종류 | Test Loss | F-1 Score | mIoU |
|---|---|---|---|
| Origin (원본, 대조군) | 0.0127 | 0.7489 | 0.6410 |
| Origin + GAN + Elastic | 0.0073 | 0.8333 | 0.7460 |
| Origin + GAN | 0.0124 | 0.7940 | 0.7038 |

*BCE LOSS ,UNET

| 증강된 데이터 종류 | Test Loss | F-1 Score | mIoU |
|---|---|---|---|
| Origin (원본, 대조군) | 0.0125 | 0.7448 | 0.6361 |
| Origin + GAN + Elastic | 0.0085 | 0.7534 | 0.6511 |
| Origin + GAN | 0.0081 | 0.7556 | 0.6705 |

*BCE LOSS ,VIT

| 증강된 데이터 종류 | Test Loss | F-1 Score | mIoU |
|---|---|---|---|
| Origin (원본, 대조군) | 0.2517 | 0.7494 | 0.6315 |
| Origin + GAN + Elastic | 0.2347 | 0.7667 | 0.6607 |
| Origin + GAN | 0.2902 | 0.7044 | 0.6010 |

*DICE LOSS ,UNET

| 증강된 데이터 종류 | Test Loss | F-1 Score | mIoU |
|---|---|---|---|
| Origin (원본, 대조군) | 0.2502 | 0.7599 | 0.6481 |
| Origin + GAN + Elastic | 0.2331 | 0.7761 | 0.6705 |
| Origin + GAN | 0.2307 | 0.7756 | 0.6824 |

*DICE LOSS , VIT

| F1 | | | | | | IOU | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|
| RN-18 | RN-50 | EN | MN-v2 | DN-121 | MVT | RN-18 | RN-50 | EN | MN-v2 | DN-121 | MVT |
| 0.780 | 0.790 | 0.781 | 0.785 | 0.791 | 0.761 | 0.674 | 0.682 | 0.674 | 0.679 | 0.686 | 0.650 |

* MosMedPlusMSBench57, 58 CT Binary 2,729 1,910/272/547

The average F1-score and IOU results for six different encoder networks. RN-18: ResNet-18; RN-50: ResNet-50; EN: Efficient-Net; MN-v2: Mobile-Net-v2; DN-121: DenseNet-121; MVT: Mix Vision Transformer

팀 소개

# TEAM 꿀벌

김 호 중 팀장

Interested in Django, cloud, k8s, mlops
Git hub : @wlrma0108

김 대 엽

Interested in robot algorithm, ui/ux
Git hub : @kdy91202

지능형 멀티미디어 시스템

# 발표를 들어 주셔서 감사합니다.

TEAM 꿀벌